


Mehr als nur Tabellenkalkulationen: Praktische Datenanalyse mit offenen Technologien

Stefan Halfpap

Folien und Workshop-Beispiele: https://github.com/klauck/practical_data_analysis_workshop

Dieser Workshop auf einer Folie


Tabellenkalkulationen



Skalierbarkeit

Automatisierung/
Abfrageworkflows

Datenanalyse mit offenen Technologien



Datenbanksysteme



SQL (Structured Query Language)


Datenformate und Werkzeuge



Visualisierung




Vorteile und Limitierungen von Tabellenkalkulationen verstehen



Möglichkeiten der Skalierung und Automatisierung mit offenen Datenmanagementtechnologien

- Überblick von (relationalen) Datenbanksystemen
- Überblick von SQL
- Datenformate und Werkzeuge/Bibliotheken
- Visualisierung





Seit 2022: PostDoc in der Gruppe „ Datenbanken und Informationssysteme“



Verteilte Datenstromverarbeitung
Datenmanagementsysteme



Davor: Doktorand in der Gruppe „Enterprise Platform and Integration Concepts“

Physische Datenbankoptimierung

Spaltenorientierte Hauptspeicher-Datenbanksysteme



Offene Daten liegen oft in Tabellenform vor

Postleitzahl	Bezirk	Gesamt	unter 6	6 - 15	...	65 und mehr
10115	Mitte	26274	1754	2051	...	1646
10117	Mitte	15531	782	881	...	2518
10119	Mitte	15064	15064	1014	...	1080
10119	Pankow	4606	336	426	...	210
:	:	:	:	:	:	:

Häufig Datenmenge zu groß um manuell zu analysieren

- Extraktion und Aggregation bestimmter Informationen


Bezirk	SUM(Gesamt)
Mitte	402289
Pankow	377941
:	:

Anwendungsfälle

- Datenpräsentation
- Berechnungen
- Datenanalyse und –visualisierung

Spezifische Programme

- Open Office
- Microsoft Excel
- Nextcloud
- Google Sheets



Vorteile

Einfache, intuitive Bedienung

- “What you see is what you get”
- Rückgängig-Funktion

Großer Funktionsumfang

- Datenpräsentation
- Berechnungen
- Datenanalyse und -visualisierung

Limitierungen

Skalierbarkeit

- große Datenmengen
- viele gleichzeitige Nutzer


Automatisierung/Abfrageworkflows

- Daten laden
- Berechnungen durchführen
- Daten direkt visualisieren
- Entscheidungen und Aktionen ableiten

Millionen Einträge auf einem Laptop analysieren

IMDb

<https://developer.imdb.com/non-commercial-datasets/>



id	tt	type	title	year	runtime	genres
12536804	tt9916800	tvEpisode	Episode #2.35	2009	\N	Drama
12536805	tt9916802	tvEpisode	Luc Janssens	2019	\N	Comedy,News,Talk-Show
12536806	tt9916804	tvEpisode	Episode #2.37	2009	\N	Drama
12536807	tt9916806	tvEpisode	Episode #3.1	2009	\N	Drama
12536808	tt9916808	tvEpisode	Episode #3.2	2009	\N	Drama
12536809	tt9916810	tvEpisode	Danira Boukhriess Terkessidis	2019	\N	Comedy,News,Talk-Show
12536810	tt9916812	tvEpisode	Episode #3.3	2009	\N	Drama
12536811	tt9916814	tvEpisode	Episode #3.4	2009	\N	Drama
12536812	tt9916816	tvEpisode	Episode #3.5	2009	\N	Drama
12536813	tt9916818	tvEpisode	Episode #3.6	2009	\N	Drama
12536814	tt9916820	tvEpisode	Episode #3.7	2009	\N	Drama
12536815	tt9916822	tvEpisode	Episode #3.8	2009	\N	Drama
12536816	tt9916824	tvEpisode	Episode #3.9	2009	\N	Drama
12536817	tt9916826	tvEpisode	Episode #3.10	2009	\N	Drama
12536818	tt9916830	tvEpisode	Episode #2.6	1973	\N	Game-Show
12536819	tt9916832	tvEpisode	Episode #3.11	2009	\N	Drama
12536820	tt9916834	tvEpisode	Episode #3.12	2009	\N	Drama
12536821	tt9916836	tvEpisode	Episode #3.14	2009	\N	Drama
12536822	tt9916838	tvEpisode	Episode #3.13	2009	\N	Drama
12536823	tt9916840	tvEpisode	Horrid Henry's Comic Caper	2014	\N	Adventure,Animation,Comedy
12536824	tt9916842	tvEpisode	Episode #3.16	2009	\N	Drama
12536825	tt9916844	tvEpisode	Episode #3.15	2009	\N	Drama
12536826	tt9916846	tvEpisode	Episode #3.18	2009	\N	Drama
12536827	tt9916848	tvEpisode	Episode #3.17	2009	\N	Drama
12536828	tt9916850	tvEpisode	Episode #3.19	2010	\N	Drama
12536829	tt9916852	tvEpisode	Episode #3.20	2010	\N	Drama
12536830	tt9916856	short	The Wind	2015	\N	Short
12536831	tt9916880	tvEpisode	Horrid Henry Knows It All	2014	\N	Adventure,Animation,Comedy
12536832						



tconst	titleType	primaryTitle	orig
startYear	endYear	runtimeMinutes	genre
tt0000001	short	Carmencita	Carm
1894	\N	1	Documentary,Short
tt0000002	short	Le clown et ses chier	
chiens	0	1892	\N 5 Anim
tt0000003	short	Poor Pierrot	Pauv
1892	\N	5	Animation,Comedy,Roma
tt0000004	short	Un bon bock	Un bo
1892	\N	12	Animation,Short
tt0000005	short	Blacksmith Scene	
0	1893	\N	1 Short
tt0000006	short	Chinese Opium Den	
0	1894	\N	1 Short
tt0000007	short	Corbett and Courtney	
1894	\N	1	Short,Sport
tt0000008	short	Edison Kinetoscopic	
Edison Kinetoscopic Record of a Sneeze	0		Documentary,Short
tt0000009	movie	Miss Jerry	Miss
1894	\N	45	Romance
tt0000010	short	Leaving the Factory	
l'usine Lumière à Lyon	0	1895	\N
Documentary,Short			
tt0000011	short	Akrobatisches Potpour	
Potpourri	0	1895	\N 1
tt0000012	short	The Arrival of a Tra	
train à La Ciotat	0	1896	\N
Documentary,Short			
tt0000013	short	The Photographical C	
Le Débarquement	0	1895	\N 1 Documentary,
tt0000014	short	The Waterer Watered	

title.basics.tsv

TSV Document - 1,09 GB

Datenbank


- (Tabellen-) Daten
- Metadaten

Datenbanksystem

- Datenbankzugriffssoftware
- Datenbankverwaltung und -abfragen

Anwendungen

- Webanwendungen, Unternehmensanwendungen, ...
- Grafische und textbasierte Oberflächen für direkten Datenbanksystemzugriff




- Umfangreiche Operationen
- Deklarative Abfragen und effiziente Verarbeitung
- Transaktionen und Datenintegrität


In den 1970er Jahren entstanden

Im Laufe der Zeit **weiterentwickelt und optimiert**
für **verschiedene Ziele**

- **Anwendungen (Funktionalität und Performanz)**
 - Eingebettete vs. Serversysteme
 - Optimiert für spezifische Abfragetypen
- **Lizenzmodelle und Kostenaspekte**
- **Service- und Bereitstellungsmodelle**
- **Nutzbarkeit**



https://hpi.de/fileadmin/user_upload/fachgebiete/naumann/projekte/RDBMSGenealogy/RDBMS_Genealogy_V6.pdf



<https://dbdb.io/>

(Relationale) Datenbanksysteme: Systemübersicht

Rank			DBMS	Database Model	Score		
Apr 2026	Mar 2026	Apr 2025			Apr 2026	Mar 2026	Apr 2025
1.	1.	1.	Oracle	Relational, Multi-model ⓘ	1157.93	-24.53	-73.12
2.	2.	2.	MySQL	Relational, Multi-model ⓘ	857.69	-0.65	-129.41
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model ⓘ	702.08	-9.40	-82.93
4.	4.	4.	PostgreSQL	Relational, Multi-model ⓘ	681.35	+1.27	+14.10
5.	5.	5.	MongoDB	Document, Multi-model ⓘ	385.02	+1.44	-15.03
6.	6.	6.	Snowflake	Relational	217.38	+6.13	+49.28
7.	7.	↑12.	Databricks	Multi-model ⓘ	150.47	+4.67	+51.19
8.	8.	↓7.	Redis	Key-value, Multi-model ⓘ	146.53	+1.35	-7.58
9.	9.	9.	IBM Db2	Relational, Multi-model ⓘ	113.25	+1.87	-12.79
10.	↑11.	↑11.	Apache Cassandra	Wide column, Multi-model ⓘ	102.62	+0.74	-5.59
11.	↓10.	↓8.	Elasticsearch	Multi-model ⓘ	99.51	-4.07	-28.57
12.	12.	↓10.	SQLite	Relational	95.90	-0.08	-18.19
13.	13.	↑14.	MariaDB ⬢	Relational, Multi-model ⓘ	86.41	-0.59	-7.93
14.	14.	↑16.	Microsoft Azure SQL Database	Relational, Multi-model ⓘ	75.96	+2.03	+0.59
15.	15.	↑18.	Apache Hive	Relational	74.13	+1.18	+1.48
16.	16.	↑17.	Splunk	Search engine	73.08	+0.87	-0.31
17.	17.	↓13.	Microsoft Access	Relational	64.92	-2.65	-30.45
18.	18.	↓15.	Amazon DynamoDB	Multi-model ⓘ	62.67	-2.75	-13.82
19.	19.	19.	Google BigQuery	Relational	52.36	-3.46	-8.37
20.	20.	20.	Neo4j	Graph	46.88	-0.44	-0.71
21.	↑22.	↑23.	SAP HANA	Relational, Multi-model ⓘ	33.23	+1.14	-0.17
22.	↓21.	↑24.	Apache Solr	Search engine, Multi-model ⓘ	33.17	+0.38	+0.77
23.	23.	↓22.	Teradata	Relational, Multi-model ⓘ	31.11	+0.03	-2.97
24.	24.	↓21.	FileMaker	Relational	28.81	-0.50	-7.67
25.	25.	25.	SAP Adaptive Server	Relational, Multi-model ⓘ	25.31	-0.22	-3.48
26.	↑28.	↑31.	ClickHouse	Relational, Multi-model ⓘ	22.87	+0.86	+4.14
27.	↓26.	↓26.	Microsoft Azure Cosmos DB	Multi-model ⓘ	22.43	-0.31	-0.12

<https://db-engines.com/en/ranking>

Ranking basiert auf:

- Erwähnungen auf Websites
- Suchtrends
- Häufigkeit technischer Diskussionen
- Stellenangeboten
- Sozialen Netzwerken

Kommerzielle Systeme

Oracle, Microsoft SQL Server, IBM Db2,
SAP HANA, Microsoft Access

Open-Source-Serversysteme

MySQL, PostgreSQL, MariaDB

Analytische Cloud-Systeme

Snowflake, Google BigQuery

Eingebettete Systeme

SQLite, DuckDB

Forschungssysteme

Hyper, Umbra, Lean Store, Hyrise, Mutable




System	Typ	Stärken	Typisches Einsatzgebiet
SQLite	Eingebettet	- Sehr leichtgewichtig - keine Konfiguration - portabel	Mobile Apps, Desktop-Anwendungen, lokale Datenspeicherung
	Client-Server-System	- erweiterte SQL Funktionen - hohe Zuverlässigkeit - viele Nutzer	Webanwendungen, Unternehmenssoftware, transaktionale Systeme
 DuckDB	Eingebettet (+ Client-Server)	- schnelle, analytische Anfragen - spaltenorientierte Verarbeitung	Data Science, interaktive Analysen


Weitere Systeme: MySQL, MariaDB, ClickHouse, ...

Anwendungen zur Datenbankinteraktion


- Grafische Benutzeroberflächen (GUI)
- Kommandozeilenprogramme
- Webdienste
- Bibliotheken für Programmiersprachen



<https://sqlitebrowser.org/>
<https://www.pgadmin.org/>
https://duckdb.org/docs/its/core_extensions/ui




<https://sqlite.org/cli.html>
<https://www.postgresql.org/docs/current/app-psql.html>
<https://duckdb.org/docs/current/clients/cli/overview>



<https://sqlite.org/fiddle/index.html>
<https://pglite.dev/repl/>
<https://shell.duckdb.org/>




<https://docs.python.org/3/library/sqlite3.html>
<https://www.psycopg.org/docs/install.html>
<https://duckdb.org/docs/current/clients/python/overview>



SQL – die Abfragesprache für relationale Datenbanksysteme

- Deklarative Abfragen
- Änderungen an Datenbeständen (INSERT, UPDATE, DELETE)
- Datenbeschreibung (Schema, Integritätsbedingungen, Indexe, ...)



```
Basic SQL commands.

For testing, you can use, for example, https://sqlite.org/fiddle/index.html

Create tables and insert data

All Commands (for a quick setup)

CREATE TABLE IF NOT EXISTS Movie (
  Title VARCHAR(30) NOT NULL,
  Year INTEGER NOT NULL,
  Length INTEGER,
  Color VARCHAR(5),
  Genre VARCHAR(20),
  StudioName VARCHAR(20),
  ProducerID INTEGER,
  PRIMARY KEY (Title, Year)
);
```


https://github.com/klauck/dbpra/blob/main/sql_intro.md

Ziel der Automatisierung

- Automatisierte Datenabfragen statt manueller SQL-Ausführung
- Reproduzierbare Datenpipelines
- Direkte Integration in Analyse- und Visualisierungsworkflows

Typischer Workflow

- Datenquelle verbinden
- SQL-Anfrage ausführen
- (Ergebnis transformieren)
- Visualisierung erzeugen



```
1 import sqlite3
2
3
4 drop_table_sql = "DROP TABLE IF EXISTS movie;"
5
6 create_table_sql = """CREATE TABLE movie (
7     movie_id INT PRIMARY KEY,
8     title VARCHAR(100),
9     genre VARCHAR(250)
10 );"""
11
12 inserts_sql = [
13     "INSERT INTO movie VALUES (1, 'Star Wars', 'sciFi');",
14     "INSERT INTO movie VALUES (2, 'Star Trek', 'sciFi');",
15     "INSERT INTO movie VALUES (3, 'Rocky', 'action');",
16 ]
17
18
19 connection = sqlite3.connect("dbpra_example.db")
20
21 cursor = connection.cursor()
22 cursor.execute(drop_table_sql)
23 cursor.execute(create_table_sql)
24 for sql in inserts_sql:
25     cursor.execute(sql)
26
27
28 cursor.execute("SELECT genre, count(*) FROM movie GROUP BY genre")
29 result = cursor.fetchall()
30
31 print(result)
32
33 import matplotlib.pyplot as plt
34
35 x = []
36 y = []
37
38 for genre, count in result:
39     x.append(genre)
40     y.append(count)
41
42 plt.xticks([0, 1, 2])
43 plt.bar(x, y)
44 plt.show()
45
```

Laptop-Hardware

- 8 - 16 CPU Kerne
- 16-32 GB RAM
- 512 GB - 1TB SSD

$$1 \text{ GB} = 1000 \text{ MB} = 10^6 \text{ kB} = 10^9 \text{ B (Bytes)}$$

Movie Eintrag

- 'Star Wars, 1977, 124, TRUE, sciFi, Fox, 12345' (45 Zeichen/Bytes)

➔ ca. 22 Millionen Einträge sind 1 GB

Datenzugriffsgeschwindigkeiten (sequenziell, ohne Datenverarbeitung)

- RAM: 100 GB/s
- SSD: 1 GB/s
- HDD: ca. 0,2 GB/s


<https://static.googleusercontent.com/media/sre.google/en//static/pdf/rule-of-thumb-latency-numbers-letter.pdf>

Datenbanksysteme: Skalierung

Datenlayout

SELECT c1, c4, c6 FROM table WHERE c4 < ?

	c1	c2	c3	c4	c5	c6
r1						
r2						
r3						
r4						
r5						
r6						
r7						



Plattner: "A Common Database Approach for OLTP and OLAP Using an In-Memory Column Database" (SIGMOD 2009)


Zeilenorientierte traditionelle textbasierte Formate:

- CSV
- JSON
- XML

```
user_id,name,birth_date,is_active,balance,signup_date
INTEGER,STRING,DATE,BOOLEAN,DECIMAL(10,2),DATE
1,Alice,1995-06-12,true,1050.75,2024-03-15
2,Bob,1990-09-28,false,250.00,2023-11-02
3,Charlie,2002-01-05,true,0.00,2025-01-10
:                                     :
```


Spaltenorientierte Binärformate (mit Metadaten)

- Parquet
- ORC
- Apache Arrow



Offene Datenformate (z.B. CSV, JSON, Parquet) → Verarbeitung von Daten ohne Datenbanksystem

- Direkt in der **Programmiersprache** (Python)
- **Bibliotheken** für effiziente Strukturen und Funktionen (z.B. NumPy, Pandas, Polars, Apache Arrow)



<https://arrow.apache.org/docs/python/api/compute.html>



Abhängig von

- Zweck
- Daten
- Eigene Erfahrung

Reimport in **Tabellenkalkulationen**




Automatisierung mit **Visualisierungsbibliotheken**




https://github.com/klauck/data_visualization_tutorial

Zusammenfassung

Tabellenkalkulationen



Datenanalyse mit offenen Technologien



Skalierbarkeit

Automatisierung/
Abfrageworkflows

Kontakt:

halfpap@tu-berlin.de

<https://halfpap.de>

Datenbanksysteme



SQL (Structured Query Language)

Datenformate und Werkzeuge



Visualisierung



Folien und Workshop-Beispiele: https://github.com/klauck/practical_data_analysis_workshop