


Mehr als nur Tabellenkalkulationen: Praktische Datenanalyse mit offenen Technologien

Stefan Halfpap


Folien und Workshop-Beispiele : https://github.com/klauck/practical_data_analysis_workshop

Dieser Workshop auf einer Folie

Tabellenkalkulationen



Datenanalyse mit offenen Technologien



Skalierbarkeit
Automatisierung/
Abfrageworkflows

Datenbanksysteme



SQL (Structured Query Language)


Datenformate und Werkzeuge



Visualisierung



Vorteile und Limitierungen von Tabellenkalkulationen verstehen




Möglichkeiten der Skalierung und Automatisierung mit offenen Datenmanagementtechnologien

- Überblick von (relationalen) Datenbanksystemen



- Überblick von SQL



- Datenformate und Werkzeuge/Bibliotheken




- Visualisierung





Seit 2022: PostDoc in der Gruppe „Datenbanken und Informationssysteme“




Verteilte Datenstromverarbeitung
Datenmanagementsysteme



Davor: Doktorand in der Gruppe „Enterprise Platform and Integration Concepts“

Physische Datenbankoptimierung

Spaltenorientierte Hauptspeicher-Datenbanksysteme



Offene Daten liegen oft in Tabellenform vor

Postleitzahl	Bezirk	Gesamt	unter 6	6 - 15	...	65 und mehr
10115	Mitte	26274	1754	2051	...	1646
10117	Mitte	15531	782	881	...	2518
10119	Mitte	15064	15064	1014	...	1080
10119	Pankow	4606	336	426	...	210
:	:	:	:	:	:	:

Häufig Datenmenge zu groß um manuell zu analysieren

- Extraktion und Aggregation bestimmter Informationen


Bezirk	SUM(Gesamt)
Mitte	402289
Pankow	377941
:	:

Anwendungsfälle

- Datenpräsentation
- Berechnungen
- Datenanalyse und –visualisierung

Spezifische Programme

- Open Office
- Microsoft Excel
- Nextcloud
- Google Sheets



Vorteile

Einfache, intuitive Bedienung

- “What you see is what you get”
- Rückgängig-Funktion

Großer Funktionsumfang

- Datenpräsentation
- Berechnungen
- Datenanalyse und -visualisierung

Limitierungen

Skalierbarkeit

- große Datenmengen
- viele gleichzeitige Nutzer


Automatisierung/Abfrageworkflows

- Daten laden
- Berechnungen durchführen
- Daten direkt visualisieren
- Entscheidungen und Aktionen ableiten

Millionen Einträge auf einem Laptop analysieren

IMDb

<https://developer.imdb.com/non-commercial-datasets/>



ID	title	type	episode number	year	other details
12536804	tt9916800	tvEpisode	Episode #2.35	2009	Drama
12536805	tt9916802	tvEpisode	Luc Janssens	2019	Comedy,News,Talk-Show
12536806	tt9916804	tvEpisode	Episode #2.37	2009	Drama
12536807	tt9916806	tvEpisode	Episode #3.1	2009	Drama
12536808	tt9916808	tvEpisode	Episode #3.2	2009	Drama
12536809	tt9916810	tvEpisode	Danira Boukhriiss Terkessidis	2019	Comedy,News,Talk-Show
12536810	tt9916812	tvEpisode	Episode #3.3	2009	Drama
12536811	tt9916814	tvEpisode	Episode #3.4	2009	Drama
12536812	tt9916816	tvEpisode	Episode #3.5	2009	Drama
12536813	tt9916818	tvEpisode	Episode #3.6	2009	Drama
12536814	tt9916820	tvEpisode	Episode #3.7	2009	Drama
12536815	tt9916822	tvEpisode	Episode #3.8	2009	Drama
12536816	tt9916824	tvEpisode	Episode #3.9	2009	Drama
12536817	tt9916826	tvEpisode	Episode #3.10	2009	Drama
12536818	tt9916830	tvEpisode	Episode #2.6	1973	Game-Show
12536819	tt9916832	tvEpisode	Episode #3.11	2009	Drama
12536820	tt9916834	tvEpisode	Episode #3.12	2009	Drama
12536821	tt9916836	tvEpisode	Episode #3.14	2009	Drama
12536822	tt9916838	tvEpisode	Episode #3.13	2009	Drama
12536823	tt9916840	tvEpisode	Horrid Henry's Comic Caper	2014	Adventure,Animation,Comedy
12536824	tt9916842	tvEpisode	Episode #3.16	2009	Drama
12536825	tt9916844	tvEpisode	Episode #3.15	2009	Drama
12536826	tt9916846	tvEpisode	Episode #3.18	2009	Drama
12536827	tt9916848	tvEpisode	Episode #3.17	2009	Drama
12536828	tt9916850	tvEpisode	Episode #3.19	2010	Drama
12536829	tt9916852	tvEpisode	Episode #3.20	2010	Drama
12536830	tt9916856	short	The Wind	2015	Short
12536831	tt9916880	tvEpisode	Horrid Henry Knows It All	2014	Adventure,Animation,Comedy
12536832					



```
tconst titleType primaryTitle orig
startYear endYear runtimeMinutes genre
tt0000001 short Carmencita Carme
1894 \N 1 Documentary,Short
tt0000002 short Le clown et ses chier
chiens 0 1892 \N 5 Anim
tt0000003 short Poor Pierrot Pauv
1892 \N 5 Animation,Comedy,Roma
tt0000004 short Un bon bock Un bo
1892 \N 12 Animation,Short
tt0000005 short Blacksmith Scene
0 1893 \N 1 Short
tt0000006 short Chinese Opium Den
0 1894 \N 1 Short
tt0000007 short Corbett and Courtney
Corbett and Courtney Before the Kine
1894 \N 1 Short,Sport
tt0000008 short Edison Kinetoscopic R
Edison Kinetoscopic Record of a Sneeze 0
Documentary,Short
tt0000009 movie Miss Jerry Miss
1894 \N 45 Romance
tt0000010 short Leaving the Factory
l'usine Lumière à Lyon 0 1895 \N
Documentary,Short
tt0000011 short Akrobatisches Potpou
Potpourri 0 1895 \N 1
tt0000012 short The Arrival of a Tra
train à La Ciotat 0 1896 \N
Documentary,Short
tt0000013 short The Photographical C
Le Débarquement du congrès de photog
1895 \N 1 Documentary,
tt0000014 short The Waterer Watered
```

title.basics.tsv

TSV Document - 1,09 GB

Datenbank


- (Tabellen-) Daten
- Metadaten

Datenbanksystem

- Datenbankzugriffssoftware
- Datenbankverwaltung und -abfragen

Anwendungen

- Webanwendungen, Unternehmensanwendungen, ...
- Grafische und textbasierte Oberflächen für direkten Datenbanksystemzugriff




- **Umfangreiche Operationen**
- **Deklarative Abfragen und effiziente Verarbeitung**
- **Transaktionen und Datenintegrität**


In den 1970er Jahren entstanden

Im Laufe der Zeit **weiterentwickelt und optimiert**
für verschiedene Ziele

- **Anwendungen (Funktionalität und Performanz)**
 - Eingebettete vs. Serversysteme
 - Optimierte für spezifische Abfragetypen
- **Lizenzmodelle und Kostenaspekte**
- **Service- und Bereitstellungsmodelle**
- **Nutzbarkeit**



https://hpi.de/fileadmin/user_upload/fachgebiete/naumann/projekte/RDBMSGenealogy/RDBMS_Genealogy_V6.pdf



<https://dbdb.io/>

(Relationale) Datenbanksysteme: Systemübersicht

Rank			DBMS	Database Model	Score		
Apr 2026	Mar 2026	Apr 2025			Apr 2026	Mar 2026	Apr 2025
1.	1.	1.	Oracle	Relational, Multi-model ⓘ	1157.93	-24.53	-73.12
2.	2.	2.	MySQL	Relational, Multi-model ⓘ	857.69	-0.65	-129.41
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model ⓘ	702.08	-9.40	-82.93
4.	4.	4.	PostgreSQL	Relational, Multi-model ⓘ	681.35	+1.27	+14.10
5.	5.	5.	MongoDB	Document, Multi-model ⓘ	385.02	+1.44	-15.03
6.	6.	6.	Snowflake	Relational	217.38	+6.13	+49.28
7.	7.	↑ 12.	Databricks	Multi-model ⓘ	150.47	+4.67	+51.19
8.	8.	↓ 7.	Redis	Key-value, Multi-model ⓘ	146.53	+1.35	-7.58
9.	9.	9.	IBM Db2	Relational, Multi-model ⓘ	113.25	+1.87	-12.79
10.	↑ 11.	↑ 11.	Apache Cassandra	Wide column, Multi-model ⓘ	102.62	+0.74	-5.59
11.	↓ 10.	↓ 8.	Elasticsearch	Multi-model ⓘ	99.51	-4.07	-28.57
12.	12.	↓ 10.	SQLite	Relational	95.90	-0.08	-18.19
13.	13.	↑ 14.	MariaDB +	Relational, Multi-model ⓘ	86.41	-0.59	-7.93
14.	14.	↑ 16.	Microsoft Azure SQL Database	Relational, Multi-model ⓘ	75.96	+2.03	+0.59
15.	15.	↑ 18.	Apache Hive	Relational	74.13	+1.18	+1.48
16.	16.	↑ 17.	Splunk	Search engine	73.08	+0.87	-0.31
17.	17.	↓ 13.	Microsoft Access	Relational	64.92	-2.65	-30.45
18.	18.	↓ 15.	Amazon DynamoDB	Multi-model ⓘ	62.67	-2.75	-13.82
19.	19.	19.	Google BigQuery	Relational	52.36	-3.46	-8.37
20.	20.	20.	Neo4j	Graph	46.88	-0.44	-0.71
21.	↑ 22.	↑ 23.	SAP HANA	Relational, Multi-model ⓘ	33.23	+1.14	-0.17
22.	↓ 21.	↑ 24.	Apache Solr	Search engine, Multi-model ⓘ	33.17	+0.38	+0.77
23.	23.	↓ 22.	Teradata	Relational, Multi-model ⓘ	31.11	+0.03	-2.97
24.	24.	↓ 21.	FileMaker	Relational	28.81	-0.50	-7.67
25.	25.	25.	SAP Adaptive Server	Relational, Multi-model ⓘ	25.31	-0.22	-3.48
26.	↑ 28.	↑ 31.	ClickHouse	Relational, Multi-model ⓘ	22.87	+0.86	+4.14
27.	↓ 26.	↓ 26.	Microsoft Azure Cosmos DB	Multi-model ⓘ	22.43	-0.31	-0.12

<https://db-engines.com/en/ranking>

Ranking basiert auf:

- Erwähnungen auf Websites
- Suchtrends
- Häufigkeit technischer Diskussionen
- Stellenangeboten
- Sozialen Netzwerken

Kommerzielle Systeme

Oracle, Microsoft SQL Server, IBM Db2,
SAP HANA, Microsoft Access

Open-Source-Serversysteme

MySQL, PostgreSQL, MariaDB

Analytische Cloud-Systeme

Snowflake, Google BigQuery

Eingebettete Systeme

SQLite, DuckDB

Forschungssysteme

Hyper, Umbra, Lean Store, Hyrise, Mutable




System	Typ	Stärken	Typisches Einsatzgebiet
SQLite	Eingebettet	- Sehr leichtgewichtig - keine Konfiguration - portabel	Mobile Apps, Desktop-Anwendungen, lokale Datenspeicherung
	Client-Server-System	- erweiterte SQL Funktionen - hohe Zuverlässigkeit - viele Nutzer	Webanwendungen, Unternehmenssoftware, transaktionale Systeme
 DuckDB	Eingebettet (+ Client-Server)	- schnelle, analytische Anfragen - spaltenorientierte Verarbeitung	Data Science, interaktive Analysen


Weitere Systeme: MySQL, MariaDB, ClickHouse, ...

Anwendungen zur Datenbankinteraktion

- Grafische Benutzeroberflächen (GUI)
- Kommandozeilenprogramme
- Webdienste
- Bibliotheken für Programmiersprachen



<https://sqlitebrowser.org/>
<https://www.pgadmin.org/>
https://duckdb.org/docs/lts/core_extensions/ui




```
(dbpr) → 02_advanced_sql git:(main) ✗ psql -h 127.0.0.1 -U postgres -d demo_db_internals - psql - psql -h 1...
psql (18.3 (Homebrew), server 17.7 (Debian 17.7-3.pgd13+1))
Type "help" for help.

demo_db_internals=# \d+
              List of relations
Schema | Name | Type | Owner  | Persistence | Access method | Size  | Description
-----+-----+-----+-----+-----+-----+-----+-----
public | student | table | postgres | permanent | heap          | 8192 bytes | 
(1 row)

demo_db_internals=# SELECT * from student;
 student_id | name | phone_number
-----+-----+-----
          1 | Sarah | 17
(1 row)

demo_db_internals=#
```

<https://sqlite.org/cli.html>
<https://www.postgresql.org/docs/current/app-psql.html>
<https://duckdb.org/docs/current/clients/cli/overview>



<https://sqlite.org/fiddle/index.html>
<https://pglite.dev/repl/>
<https://shell.duckdb.org/>



```
import sqlite3

create_table_sql = """CREATE TABLE customer (
  c_id INT PRIMARY KEY,
  c_name VARCHAR(50),
  zip_code VARCHAR(20)
);"""
insert_sql = "INSERT INTO customer VALUES (1, 'Sarah', 10963);"


connection = sqlite3.connect("dbpr_example.db")
cursor = connection.cursor()
cursor.execute(create_table_sql)
cursor.execute(insert_sql)

cursor.execute("SELECT * FROM customer")
result = cursor.fetchall()
print(result)
```

<https://docs.python.org/3/library/sqlite3.html>
<https://www.psycopg.org/docs/install.html>
<https://duckdb.org/docs/current/clients/python/overview>

SQL – die Abfragesprache für relationale Datenbanksysteme

- Deklarative Abfragen
- Änderungen an Datenbeständen (INSERT, UPDATE, DELETE)
- Datenbeschreibung (Schema, Integritätsbedingungen, Indexe, ...)



```
CREATE TABLE IF NOT EXISTS Movie (  
  Title VARCHAR(30) NOT NULL,  
  Year INTEGER NOT NULL,  
  Length INTEGER,  
  Color VARCHAR(5),  
  Genre VARCHAR(20),  
  StudioName VARCHAR(20),  
  ProducerID INTEGER,  
  PRIMARY KEY (Title, Year)  
);
```


https://github.com/klauck/dbpra/blob/main/sql_intro.md

Ziel der Automatisierung

- Automatisierte Datenabfragen statt manueller SQL-Ausführung
- Reproduzierbare Datenpipelines
- Direkte Integration in Analyse- und Visualisierungsworkflows

Typischer Workflow

- Datenquelle verbinden
- SQL-Anfrage ausführen
- (Ergebnis transformieren)
- Visualisierung erzeugen



```
1 import sqlite3
2
3
4 drop_table_sql = "DROP TABLE IF EXISTS movie;"
5
6 create_table_sql = """CREATE TABLE movie (
7     movie_id INT PRIMARY KEY,
8     title VARCHAR(100),
9     genre VARCHAR(250)
10 );"""
11
12 inserts_sql = [
13     "INSERT INTO movie VALUES (1, 'Star Wars', 'sciFi');",
14     "INSERT INTO movie VALUES (2, 'Star Trek', 'sciFi');",
15     "INSERT INTO movie VALUES (3, 'Rocky', 'action');",
16 ]
17
18
19 connection = sqlite3.connect("dbpra_example.db")
20
21 cursor = connection.cursor()
22 cursor.execute(drop_table_sql)
23 cursor.execute(create_table_sql)
24 for sql in inserts_sql:
25     cursor.execute(sql)
26
27
28 cursor.execute("SELECT genre, count(*) FROM movie GROUP BY genre")
29 result = cursor.fetchall()
30
31 print(result)
32
33 import matplotlib.pyplot as plt
34
35 x = []
36 y = []
37
38 for genre, count in result:
39     x.append(genre)
40     y.append(count)
41
42 plt.xticks([0, 1, 2])
43 plt.bar(x, y)
44 plt.show()
45
```

Laptop-Hardware

- 8 - 16 CPU Kerne
- 16-32 GB RAM
- 512 GB - 1TB SSD

$$1 \text{ GB} = 1000 \text{ MB} = 10^6 \text{ kB} = 10^9 \text{ B (Bytes)}$$

Movie Eintrag

- 'Star Wars, 1977, 124, TRUE, sciFi, Fox, 12345' (45 Zeichen/Bytes)

➔ ca. 22 Millionen Einträge sind 1 GB

Datenzugriffsgeschwindigkeiten (sequenziell, ohne Datenverarbeitung)

- RAM: 100 GB/s
- SSD: 1 GB/s
- HDD: ca. 0,2 GB/s


<https://static.googleusercontent.com/media/sre.google/en//static/pdf/rule-of-thumb-latency-numbers-letter.pdf>

Datenbanksysteme: Skalierung

Datenlayout

SELECT c1, c4, c6 FROM table WHERE c4 < ?

	c1	c2	c3	c4	c5	c6
r1						
r2						
r3						
r4						
r5						
r6						
r7						



Plattner: "A Common Database Approach for OLTP and OLAP Using an In-Memory Column Database" (SIGMOD 2009)

Zeilenorientierte traditionelle textbasierte Formate:


- CSV
- JSON
- XML

```
user_id,name,birth_date,is_active,balance,signup_date
INTEGER,STRING,DATE,BOOLEAN,DECIMAL(10,2),DATE
1,Alice,1995-06-12,true,1050.75,2024-03-15
2,Bob,1990-09-28,false,250.00,2023-11-02
3,Charlie,2002-01-05,true,0.00,2025-01-10
:                                     :
```

Spaltenorientierte Binärformate (mit Metadaten)


- Parquet
- ORC
- Apache Arrow

```
COPY (
SELECT *
FROM read_csv_auto(title.basics.tsv ' ')
) TO 'title.parquet' (FORMAT PARQUET);
```



Offene Datenformate (z.B. CSV, JSON, Parquet) → Verarbeitung von Daten ohne Datenbanksystem

- Direkt in der **Programmiersprache** (Python)
- **Bibliotheken** für effiziente Strukturen und Funktionen (z.B. NumPy, Pandas, Polars, Apache Arrow)



<https://arrow.apache.org/docs/python/api/compute.html>



Abhängig von

- Zweck
- Daten
- Eigene Erfahrung

Reimport in **Tabellenkalkulationen**




Automatisierung mit **Visualisierungsbibliotheken**




https://github.com/klauck/data_visualization_tutorial

Zusammenfassung

Tabellenkalkulationen



Datenanalyse mit offenen Technologien



Skalierbarkeit

Automatisierung/
Abfrageworkflows

Kontakt:

halfpap@tu-berlin.de

<https://halfpap.de>

Datenbanksysteme



SQL (Structured Query Language)

Datenformate und Werkzeuge



Visualisierung



Folien und Workshop-Beispiele: https://github.com/klauck/practical_data_analysis_workshop